

입찰메이트 RFP RAG 시스템 개발 보고서

공공 IT RFP 100건 · 추출 · 요약 · 추천 · 적격성 판정 — 정량 실험으로 최적 구성 확정

작성자 김건오 (2팀) · 최종 구성 bge-m3 + EXAONE-3.5-7.8B + 하이브리드 검색 · GCP VM 자체호스팅

100

대상 RFP(건)

1,107

임베딩 청크

0.933

검색 Hit@1

2.6×

응답 속도(vs OpenAI)

344

평가 골든셋(건)

1. 요약 (Executive Summary)

- 공공 IT RFP를 임베딩·검색하여 근거 기반으로 답변하는 **RAG 시스템**을 구축하고, 추천·요약·적격성 판정을 제공하는 웹 서비스를 완성하였다.
- 임베딩·검색·생성 LLM의 모든 선택은 **골든셋 기반 정량 실험**을 통해 결정하였다.
- 한국어 도메인에서는 **오픈모델 자체호스팅**(bge-m3 + EXAONE)이 OpenAI 대비 성능은 동등 이상이면서 무료·기밀보호 측면에서 우위임을 확인하였다.
- 개발 과정에서 발생한 검색 변별력 저하, 모델 환각 등의 문제를 **실험에 근거하여** 해결하였다.

2. 프로젝트 개요 & 설계 원칙

나라장터에는 일 수백 건의 RFP가 등록되며, 각 문서는 수십 페이지 분량(HWP/PDF)으로 컨설턴트가 개별적으로 검토하기 어렵다. 본 과제는 핵심 정보(발주기관·예산·자격·요구조건)의 신속한 파악과 입찰 참여 여부 판단을 지원하는 것을 목표로 하였다.

표 1. 두 가지 핵심 설계 원칙

원칙	내용	효과
교체 가능한 추상화	임베딩·LLM·벡터스토어를 base(규격)+구현체+팩토리 3단 추상화. <code>.env</code> 만 바꿔 OpenAI ↔ 자체호스팅 전환	코드 0줄 수정으로 모델·백엔드 비교·전환
정량 실험 기반 의사결정	모든 모델·설정 변경을 골든셋 지표로 비교해 results/에 기록	주관 배제, 근거 있는 채택

개발 진행 과정 (5단계)



3. 시스템 아키텍처




그림 1. 전체 아키텍처 — 인덱싱 파이프라인(사전 1회) · RAG 엔진(질의 시) · 웹(React↔FastAPI)

표 2. 3단 추상화 계층 — 같은 코드로 OpenAI ↔ 자체호스팅 전환

계층	추상 인터페이스	1단계(OpenAI)	2단계(자체호스팅, 채택)
임베딩	BaseEmbedder	text-embedding-3-small	bge-m3 (Ollama)
생성 LLM	BaseLLM	gpt-5-mini	EXAONE-3.5-7.8B (Ollama)

계층	추상 인터페이스	1단계(OpenAI)	2단계(자체호스팅, 채택)
벡터 저장소	BaseVectorStore	ChromaDB	ChromaDB (동일)

핵심 기법 — Ollama가 OpenAI 호환 API를 제공하므로, `provider=openai` 와 `base_url` 설정만으로 기존 OpenAI 코드가 EXAONE-bge-m3를 그대로 구동한다. torch/transformers가 불필요하여 경량이며 파이썬 버전 제약이 없다.

질의 처리 흐름

질문/프로필 → ① 질의 재작성 (자연어→키워드) → ② 하이브리드 검색 (BM25+dense, RRF)
→ ③ LLM 재랭킹 (EXAONE) → context 구성 → ④ 프롬프트 → LLM → 답변 + 출처

4. 데이터 파이프라인 & 평가 체계

배포 zip을 해제하여 문서와 메타데이터를 분류하고(깨진 한글 파일명은 cp437→cp949로 복원), 정제·청킹을 거쳐 벡터로 적재하였다. EDA 과정에서 **텍스트 품질 문제**를 발견하여 원본 재추출 및 정제로 보강하였다.

표 3. 데이터 현황 및 품질 보강 결과

항목	값	비고
원본 문서	100건 (HWP 96 / PDF 4)	HWP가 96% → HWP 추출 우선
짧은 문서 재추출 보강	21건	본문 89자 → 약 20,000자
깨진 문자 정제	PUA 252 · U+FFFD 588	추출 기호 + 토큰 경계 두 원인 분리 처리
최종 청크	1,107청크	토큰 기반 청킹(.env로 크기 제어)

표 4. 평가 체계 — 검색·생성 품질을 정량화

골든셋	건수	지표 / 용도
메타데이터형(자동)	285건	Hit@k · MRR — 검색 품질(청킹·임베딩·검색방식 튜닝)
내용형(직접 작성)	59건	정답포함 · LLM-judge — 생성/답변 품질(문서 원문 근거로 중립 작성)

5. 핵심 실험 결과 & 의사결정

각 실험 결과를 막대차트로 제시하였다. 보라색 막대가 채택 후보이다.

검색 방식 · Hit@1 (정답이 1순위로 검색된 비율)

dense 0.807

하이브리드(RRF) 0.933

하이브리드가 dense 대비 +12.6%p. MRR도 0.861 → 0.953 로 동반 상승.

임베딩 모델 · Hit@1 (하이브리드 기준)

bge-m3 (자체) 0.961

KURE-v1 (자체) 0.958

OpenAI 3-small 0.937

한국어 데이터에서 오픈모델(bge-m3-KURE)이 OpenAI 임베딩을 능가.

경량 LLM · 추출 정확도

exaone3.5:2.4b 0.467

gemma2:2b 0.367

qwen2.5:3b 0.333

동일 크기대에서 한국어 특화 EXAONE이 gemma-qwen을 크게 앞섬.

배포 LLM · 추출 정확도 (동률)

EXAONE-3.5-7.8B 0.533

gpt-5-mini 0.533

정확도는 동률(0.533). 무료·기밀보호·속도에서 자체호스팅이 우위.

배포 LLM · 응답 시간 (중앙값, 낮을수록 좋음)

EXAONE-3.5-7.8B 3.78s

gpt-5-mini 9.81s

정확도 동률이지만 EXAONE이 약 2.6배 빠름.

답변 품질 · LLM-judge 교차검증 (5점 만점)

EXAONE (평균) 4.37

gpt-5-mini (평균) 4.20

두 심판 모두 EXAONE을 더 높게 평가. 상대 심판 gpt조차 EXAONE(4.31) > 자기(4.14) → 자기편향 아님.

표 5. 실험 종합 및 결정

실험	비교	결과(정량)	결정
검색 방식	dense vs 하이브리드	Hit@1 0.807 → 0.933 · MRR 0.861 → 0.953	하이브리드(RRF)
임베딩	OpenAI vs 오픈모델	bge-m3 0.961 > KURE 0.958 > OpenAI 0.937	bge-m3 (무료·한국어)
LLM(경량)	2~3B 3종	exaone 0.467 > gemma 0.367 > qwen 0.333	한국어 특화 EXAONE
LLM(배포)	EXAONE 7.8B vs gpt-5-mini	정확도 0.533 동물, 응답 2.6배 빠름	EXAONE-3.5-7.8B
답변 품질	LLM-judge 교차검증	EXAONE 4.37 vs gpt 4.20	EXAONE 신뢰(편향 없음)

의사결정 1 검색 = 하이브리드(BM25+dense, RRF)

체크 크기 가설을 실험으로 반증하고 전 지표 우위인 하이브리드로 확정. 실패 질의를 14위 밖에서 1위로.

의사결정 2 임베딩 = bge-m3 (자체호스팅)

한국어 검색에서 오픈모델이 OpenAI를 능가(0.961 vs 0.937). 무료·기밀보호까지 확보.

의사결정 3 생성 LLM = EXAONE-3.5-7.8B (자체호스팅)

정확도 동물·응답 2.6배·무료. 교차검증에서 상대 심판 gpt조차 EXAONE을 높게 평가 → 신뢰할 근거.

최종 구성 · bge-m3 + EXAONE-3.5-7.8B + 하이브리드 검색 · GCP VM(L4) 자체호스팅

6. 트러블슈팅 & 그 안의 의사결정

발생한 문제·원인과 어떤 판단으로 해결했는지. 강조된 행은 프로젝트 방향을 바꾼 핵심 결정이다.

표 6. 개발 트러블슈팅 종합

문제	원인	해결 / 의사결정
OpenAI 임베딩 반복 실패	계정 rate limit 0	담당자에 진단 공유 → 한도 상향
검색 변별력 저하	질의 표현(일반어가 핵심어 희석) ※ 청크 크기 가설은 실험으로 반증	질의 재작성성 + 하이브리드 검색 도입
깨진 문자(💎) 잔존	PUA 기호 + 토큰 슬라이싱 경계	정제 단계 이원화(clean / chunker)
Qwen 한국어에 중국어 혼입	중국 모델 특성	한국어 특화 EXAONE로 교체
VM 메모리 부족 중단	모델 동시 구동	1개씩 실행 + nohup 백그라운드
외부 접속 불가	방화벽 · 바인딩	포트 개방(내 IP) + 0.0.0.0 바인딩
AI 요약 산문형·부정확 출력	EXAONE 형식 이탈, 온도 0.8	few-shot 예시 + 온도 0.2 + 강건한 파서
장문 요약 시 항목 누락	핵심(사업개요) 청크 검색 누락	확정 항목은 카탈로그 메타데이터로 직접 보정
적격성 판정 전면 실패	EXAONE가 실제 자격조항 대신 일반론을 환각 "기술적/재무적 요건 모두 적합" 창작 — 모델 능력 한계	해당 과제만 gpt-5-mini 라우팅(옵트인), 키 없으면 EXAONE 풀백

핵심 판단 — 프롬프트 및 파서 보강만으로는 EXAONE의 환각을 억제할 수 없음을 raw 출력으로 진단하고, 전체 모델을 교체하는 대신 **해당 과제에 한하여** 성능이 우수한 모델로 라우팅하는 방식을 채택하였다. 검증 결과 gpt-5-mini는 고압가스 RFP와 의료기기 회사 사례에서 실제 자격조항 20개(소프트웨어사업자 신고확인서·실적증명서·신용평가등급 등)를 정확히 추출하고 전부 '확인필요'로 판정하였다. 이로써 요약·검색·질의응답은 EXAONE로 유지하는 자체호스팅 원칙을 보존하였다.

7. 최종 시스템 기능

표 7. 웹 서비스 제공 기능과 사용 기술

기능	설명	핵심 기술
맞춤 추천	자연어 프로필 → 의미 이해해 적합 공고 재정렬, 없으면 나라 장터 풀백	하이브리드 검색 + LLM 재랭킹
AI 요약	고정 10항목 표로 문서 간 비교 용이(사업명·예산·자격·마감일 등)	EXAONE + 메타데이터 보정
적격성 판정	회사 프로필 vs RFP 자격 대조 → 1차 판정 + 2차 확인, 체스 등급 배지	gpt-5-mini 라우팅
질의응답	근거(출처) 기반 답변, 환각 억제	RAG(EXAONE)
임시저장·내보내기	문서별 항목 선택 → 엑셀(CSV)로 내보내기	React + localStorage

8. 핵심 인사이트 & 결론

- **한국어 도메인에선 오픈모델이 OpenAI를 능가** — 임베딩·LLM 모두 자체호스팅이 성능·비용·기밀보호 우위. 파라미터 크기보다 '한국어 특화'가 결정적.
- **가설은 실험으로 검증** — "체크 크기가 문제일 것"을 반증하고 진짜 원인(질의 표현)을 규명.
- **LLM 한계는 아키텍처로 흡수** — 확정 항목은 메타데이터로 채우고, 어려운 추론(적격성)은 능력 있는 모델로 라우팅.
- **제약 환경의 현실적 배포** — sudo·웹전용·메모리 제약 속에서 Ollama 홈설치·노트북 데모로 시연 목표 달성.

종합 : 데이터 파이프라인 → 검색 품질 개선 → 자체호스팅 모델 확정 → 서비스·비즈니스 기능까지 전 단계를 정량 근거로 구축하고 실행작을 검증했다. 적격성 판정의 모델 한계까지 라우팅 설계로 해결하여, RFP를 추출·요약·추천·적격성 판정하는 **완결된 RAG 서비스**를 완성했다.